

One Banking AI

IA no setor financeiro · governança · soberania · economia de IA · Curadoria: Team Sector Banking

COMO LER ESTE BRIEFING

Selos:  **Impacto direto no negócio** = movimento de cliente/concorrente/regulador que afeta a operação agora.  **Primeira mão** = item captado direto na fonte BR, fora das newsletters globais. Internacional entra como contexto/comparação, não como manchete — salvo marco global incontornável.
Uso interno e confidencial — cruza com o estudo Where To Play Banking · One Banking (MTP 27-29).

< A LEITURA DE HOJE

A percepção de ROI de IA nos bancos brasileiros subiu 14 pontos. O problema é que "percepção de ROI" sem baseline de custo de inferência é fé, não FinOps — e o CEO da Zafin acabou de dizer, com o JPMorgan gastando US\$ 2 bi/ano como pano de fundo, que a razão pela qual os bancos não veem resultado não é o modelo: é que ninguém mediu o denominador.

Repare no encontro de duas fontes hoje. De um lado, a Zafin (via Boboev) argumenta que os bancos não colhem resultado de IA porque tratam o problema como *tecnologia* quando ele é de *arquitetura de produto e dado*. De outro, a Febraban 2026 mostra os bancos BR na fase eufórica: **R\$ 826 mi em IA (+39%)**, percepção de ROI **+14pp**, IA/GenAI como prioridade para 84%. As duas leituras não se contradizem — descrevem o mesmo ciclo em pontos diferentes. O Brasil está agora onde os EUA estavam há 18 meses: investindo pesado e *sentindo* que funciona, antes de ter o instrumento que prova.

O QUE EU DIRIA NUM BOARD

o número perigoso da Febraban não é o R\$ 826 mi — é o **"percepção de ROI +14pp"**. Percepção é autorrelato, e autorrelato de ROI sem o custo de inferência no denominador é o que o MIT mede ao dizer que **95% das organizações veem zero retorno mensurável** (pág. 5): a lacuna entre *sentir* e *provar*. O contraponto honesto — e eu o diria em voz alta — é que percepção positiva não é ruído: reflete ganhos operacionais reais. Mas ganho operacional percebido não é ROI; ROI é ganho *menos* o custo total de servir o modelo — e é esse custo que ninguém mede. O NTT DATA dá o caminho: **84,1% dos que alinham estratégia de IA e negócio reportam ≥5% de uplift de lucro** (pág. 4). **A diferença entre o banco que vê ROI e o que só o percebe não é quanto gasta em IA — é se sabe quanto a IA lhe custa.**

PRA USAR AMANHÃ

levar ao comitê uma pergunta de uma linha: **"qual é o nosso custo de inferência por caso de uso, e o ROI que reportamos é ganho bruto ou líquido desse custo?"** Se a resposta

for “produtividade percebida”, o diagnóstico está feito — e é o denominador que a Veltrix instrumenta. Com o Kimi K3 a 40% do preço da classe Opus, o numerador vai cair; só quem mede o denominador transforma isso em margem.

IA em Serviços Financeiros

Febraban 2026: bancos BR vão investir R\$ 50,4 bi em tecnologia, R\$ 826 mi só em IA — percepção de ROI sobe 14pp

△ Impacto direto no negócio

➔ Primeira mão

BR

A 34ª Pesquisa Febraban de Tecnologia Bancária (jun/2026, Deloitte) projeta **R\$ 50,4 bi em tecnologia em 2026** (+8% sobre R\$ 46,8 bi de 2025). O gasto em **IA somou R\$ 826 mi em 2025** (+39% sobre R\$ 596 mi de 2024). Prioridades: cibersegurança (100%), cloud (84%), IA/GenAI (até 84%). E o humor do setor: a **percepção de ROI da IA cresceu 14 pontos percentuais**. (Febraban/Deloitte; IT Forum; Forbes, jun–jul/2026)

O QUE EU DIRIA NUM BOARD

a Febraban confirma que a IA saiu do laboratório — mas o indicador a interrogar é a *percepção* de ROI, não o volume investido. R\$ 826 mi é input; percepção é sentimento; ROI é a razão entre os dois, com o custo de servir no denominador. Cruzando com o MIT (95% com zero retorno, pág. 5) e o NTT DATA (retorno aparece em quem alinha e mede, pág. 4): o próximo salto não vem de gastar mais — vem de instrumentar o custo para provar o retorno.

PRA USAR AMANHÃ

pedir que o próximo report de IA ao board troque “percepção de ROI” por **ROI medido** em pelo menos um caso de uso — ganho quantificado menos custo total de inferência.

Itaú expande ia.i e agentes de engenharia (migração 6x com Devin); Bradesco escala a BRIDGE

BR

contexto

O **Itaú** segue a esteira agêntica: além do assistente conversacional **ia.i** (em teste, substituindo menus por linguagem natural), relatou **acelerar migração de serviços em 6x** com agente (Devin) e mantém **1,3 mil+ modelos de IA em uso**, com GenAI como “camada estrutural” (+88%). O **Bradesco** responde com a **BRIDGE: 1.000+ modelos** pré-definidos, camada de IA responsável, além da BIA (desde 2017) e do Renda BRA (via Kunumi). (TI Inside; IT Forum; Mobile Time, jun–jul/2026)

O QUE EU DIRIA NUM BOARD

os dois maiores privados BR correm com estratégias espelhadas — Itaú na *interface* (agente que fala com cliente e engenheiro), Bradesco na *plataforma* (mil modelos governados). Ambos ilustram o item-líder: são movimentos de *capacidade*, medidos em velocidade e volume — não em ROI líquido. “1,3 mil modelos” é número de portfólio, não

de retorno. A pergunta de CAIO: desses milhares, quantos têm custo medido e dono de resultado? Portfólio grande sem FinOps é passivo de inferência disfarçado de vantagem.

PRA USAR AMANHÃ

em avaliação de parceria com esses bancos, o ângulo de entrada não é “mais IA” — é **governança de custo do estate de modelos** (Veltrix) e **mandato dos agentes em produção** (Cohort). É onde a corrida deles ainda tem lacuna aberta.

Economia de IA & FinOps

Kimi K3 (2,8T-A50B): modelo aberto classe-Opus 4.8 a 40% do preço muda o “build vs buy”

contexto global

A **Moonshot AI** lançou (16/07) o **Kimi K3**, maior modelo aberto já liberado — **2,8T parâmetros (50B ativos, MoE)**, contexto de 1M tokens, multimodal. Pontua **57 no Artificial Analysis Index** (par com Opus 4.8 e GPT-5.5) a **US\$ 3/US\$ 15 por 1M tokens** contra US\$ 5/US\$ 25 do Opus 4.8 — **40% mais barato. Peso aberto prometido para 27/07.** (AINews/Latent Space; The Decoder; kie.ai, 16/07/2026)

O QUE EU DIRIA NUM BOARD

a manchete é o preço; a leitura de banco é a *derivada*. Quando um modelo classe-Opus 4.8 fica a 40% do custo — e, em três semanas, como peso aberto self-hostável — o custo de inferência do numerador desaba. Isso não resolve o paradoxo de ROI; ele o *aprofunda*: inferência barata e abundante faz o volume explodir, e sem instrumentação o board perde ainda mais a noção do gasto por caso de uso. Inferência barata não é o fim do FinOps de IA — é o começo.

PRA USAR AMANHÃ

mapear os fluxos que hoje pagam preço-Opus em API fechada e testar migrar para Kimi K3 (fechado agora, self-hosted após 27/07). A conta — custo de API vs. self-host por sensibilidade — é o relatório que a Veltrix gera.

Zafin (via Boboev): “a verdadeira razão pela qual bancos não veem resultado de IA” — JPMorgan investe US\$ 2 bi/ano

contexto global

Charbel Safadi (CEO da Zafin), em conversa publicada por Sam Boboev (17/07), argumenta que o gargalo de ROI de IA nos bancos não é o modelo, e sim a **arquitetura de produto e a fragmentação de dado/legado** — bancos acoplam IA a processos velhos e esperam resultado novo. Contexto: o **JPMorgan investe mais de US\$ 2 bi/ano** em IA/tecnologia. (Sam Boboev / Fintech Wrap Up, 17/07/2026)

O QUE EU DIRIA NUM BOARD

Safadi diz em linguagem de fintech o que o MIT diz em pesquisa (95% com zero retorno, pág. 5): o retorno não falha por falta de modelo, falha por falta de *reengenharia*. Mas eu iria além: mesmo reengenhariando o produto, o banco segue cego ao ROI se não medir o custo de servir a IA. Arquitetura de produto é condição necessária; FinOps de inferência é a que prova. US\$ 2 bi/ano sem custo por caso de uso é o maior autorrelato de ROI do mundo — e o mais difícil de auditar.

PRA USAR AMANHÃ

usar a fala da Zafin como abertura com áreas de negócio (“o problema não é o modelo, é o processo”) e fechar com o instrumento que falta (“e o processo só melhora se medirmos o custo — este é o relatório”).

Agentes & Força de Trabalho

Agentic commerce sai do piloto: Visa+OpenAI e Mastercard “Agent Pay for Machines” habilitam pagamento máquina-a-máquina

contexto global

A **Visa** integrou pagamento às experiências da OpenAI (credenciais tokenizadas, autorização em tempo real, monitoramento de fraude). A **Mastercard** lançou o **Agent Pay for Machines** com 30+ parceiros (Stripe, Adyen, Checkout.com, Global Payments, Solana) — software transacionando com software. A McKinsey projeta **US\$ 1 tri em vendas B2C nos EUA via agentic commerce até 2030**; a TD Bank relata **55% dos americanos usando IA para gerir finanças** (vs. 10% um ano antes). (American Banker; Mastercard; Digital Commerce 360, 2026)

O QUE EU DIRIA NUM BOARD

agentic commerce virou trilho de pagamento em produção — e abre uma frente que nenhum antifraude tradicional cobre: **quando o comprador é um agente, ‘conheça seu cliente’ vira ‘conheça o agente do seu cliente’**. Quem detém o mandato do agente que gasta? Qual o limite, escopo, jurisdição, trilha daquela compra? O Brasil, com Pix e Open Finance, é terreno fértil para isso chegar rápido — e o arcabouço de KYC/AML não foi desenhado para contrapartes de software.

PRA USAR AMANHÃ

propor um one-pager de “governança de agente comprador” — mandato, limite, jurisdição e trilha por agente — antes que o primeiro Pix agêntico force a discussão. É o mandato de agente que o Cohort escreve.

Soberania

Peso aberto classe-fronteira (Kimi K3, 27/07) torna residência de dado economicamente viável para carga sensível

contexto global

A promessa de **peso aberto em 27/07** coloca um modelo classe-Opus 4.8 rodável **na própria infraestrutura**, sem enviar prompt ao provedor. Somado ao Inkling (Thinky, Apache 2.0, ed. Nº 32), consolida uma safra de modelos abertos competitivos como vetor concreto de residência de dados. (AINews, 16/07/2026)

O QUE EU DIRIA NUM BOARD

para quem trata soberania como núcleo (o NTT DATA diz **62,5% dos líderes** tratam privacidade cross-geography e soberania como preocupação de board, pág. 5), o que mudou este mês não é a *possibilidade* de rodar aberto — é a *economia* dela. Com K3 e Inkling, a conta de self-host para dado sensível fica competitiva. Soberania deixa de ser custo de convicção e vira decisão de FinOps — e é aí que ela entra na pauta do board sem precisar de discurso.

PRA USAR AMANHÃ

recalcular o “build vs buy” da inferência sensível com os novos preços de peso aberto — o ponto de equilíbrio se moveu; fluxos que não cabiam em self-host há um mês talvez caibam agora.

Regulatório Brasil

Bacen mantém “estudo dos riscos de IA nas instituições financeiras” como meta 2025/26; Drex pivota para reconciliação de garantias

↗ Primeira mão

BR

O **Banco Central** mantém como meta do biênio **2025/26** o *estudo dos riscos do uso de IA pelas instituições financeiras*, numa agenda que integra Pix, Open Finance, tokenização e IA. O **Drex** mudou de direção: abandonou o blockchain público (Hyperledger Besu) e passou a focar em **reconciliação de garantias (lien reconciliation)**. (Abranet; DeFin Insights; Finsiders, 2026)

O QUE EU DIRIA NUM BOARD

o Bacen sinaliza que **regulação de IA no financeiro BR virá por risco, não por princípio** — o “estudo dos riscos” prenuncia exigências de governança (explicabilidade, trilha, controle de modelo) que vão aterrissar sobre os 1,3 mil / 1.000+ modelos de Itaú e Bradesco. Para o CAIO: a casa que já tem inventário e mandato de modelos chega pronta quando a norma sair; a que só tem portfólio chega correndo.

PRA USAR AMANHÃ

começar o inventário de modelos com classificação de risco *antes* do Bacen pedir — quem já governa o estate transforma exigência regulatória em custo marginal, não em projeto de emergência.

- **Peso aberto do Kimi K3 (27/07):** confirmar licença e viabilidade real de self-host para carga sensível. *BR-relevante*.
- **Percepção vs. medição de ROI:** monitorar se algum bancão BR publica ROI *medido* (não percebido) — seria o primeiro a sair da fé para o FinOps.
- **Primeiro Pix/pagamento agêntico:** vigiar quando um agente comprador cruza o trilho brasileiro — força a discussão de KYC de contraparte-software.
- **Meta de risco de IA do Bacen:** acompanhar se o “estudo” evolui para consulta pública/norma no 2º semestre.

Termômetro do dia

R\$ 826 mi

Gasto dos bancos BR em IA em 2025, +39% (Febraban/Deloitte)

95%

Organizações com zero retorno mensurável de IA (MIT, pág. 5)

40%

Desconto do Kimi K3 sobre o Opus 4.8, a intelligence comparável (Artificial Analysis)

US\$ 1 tri

Vendas B2C nos EUA via agentic commerce até 2030 (McKinsey)

Aprendizado do dia — “baseline de custo”

ROI de IA = (ganho – custo total de servir o modelo) ÷ custo. O erro recorrente do setor é reportar só o numerador (ganho percebido) e esquecer o denominador (custo de inferência: tokens, rota, infra de self-host, retries). Sem baseline de custo por caso de uso, “percepção de ROI” mede entusiasmo, não retorno. FinOps de IA é, antes de tudo, medir o denominador — e por isso inferência *mais barata* (Kimi K3) torna o FinOps *mais* necessário, não menos: volume que escala sem medição é gasto que escala sem controle.

Fontes do dia

Febraban/Deloitte — 34ª Pesquisa de Tecnologia Bancária 2026 · IT Forum · Forbes Brasil · Sam Boboev / Fintech Wrap Up (Zafin) · AINews/Latent Space · The Decoder · kie.ai (Kimi K3) · American Banker · Mastercard · Digital Commerce 360 (agentic commerce) · TI Inside · Mobile Time (Itaú/Bradesco) · Abranet · DeFin Insights · Finsiders (Bacen/Drex).
Reports internos: MIT — *Culture Eats AI for Breakfast* (pág. 5) · NTT DATA — *Banking AI Leaders' Playbook 2026* (pág. 4-5) · *Where To Play Banking* · *One Banking* (MTP 27-29).