

One Banking AI

IA no setor financeiro · governança · soberania · economia de IA

TERÇA-FEIRA · 28 · JULHO · 2026 EDIÇÃO Nº 38

COMO LER ESTE BRIEFING

▲ **IMPACTO DIRETO NO NEGÓCIO** movimento de cliente/concorrente/regulador que afeta a operação agora. ◆ **PRIMEIRA MÃO** item captado direto na fonte BR, fora das newsletters globais.

Internacional entra como contexto/comparação, não como manchete. *Uso interno e confidencial* — cruza com o estudo Where To Play Banking · One Banking (MTP 27-29).

TERMÔMETRO DO DIA

300 mil

clientes no arranque do ia.i do Itaú — base completa até o fim de 2026

▲ TI Inside, 27/07

-65%

custo de GenAI do Itaú com plataforma própria multi-provedor

◆ TI Inside, 27/07

2,8 tri

parâmetros do Kimi K3, maior open-weight da história (104 bi ativos)

● Tom's Hardware, 27/07

43,5%

das mensagens ocupacionais no ChatGPT cruzam a fronteira da profissão

▲ OpenAI, 27/07

⚡ A LEITURA DE HOJE

O Itaú não lançou um chatbot — trocou o canal primário do banco. E o número que sustenta a jogada é de FinOps: -65% no custo de GenAI.

O **ia.i** assume a tela inicial do app: voz, texto ou imagem no lugar dos menus, com conta, cartões, crédito, investimentos e seguros num só ambiente conversacional. Arranque com **~300 mil clientes**, base completa **até o fim de 2026**. A engenharia por trás: plataforma própria multi-provedor (**OpenAI, Anthropic, Google, AWS**, modelos abertos e fechados) com **redução de 65% no custo de IA generativa**. Conversa em escala de dezenas de milhões de clientes só fecha conta com roteamento de modelos (model routing) — sem isso, o ia.i seria um centro de custo com boa UX. E o risco muda de lugar: menu não aconselha, conversa aconselha — a trilha de auditoria de cada resposta vale mais que a interface.

Itaú lança o ia.i: a IA assume a tela inicial do app, com 300 mil clientes e -65% de custo de GenAI

Follow-up da ed. Nº 32 (ia.i em teste com base restrita): agora é **lançamento oficial**, apresentado em SP (27/07). Interação por **voz, texto ou imagem** substituindo menus; conta, cartões, crédito, investimentos e seguros num só ambiente; **~300 mil clientes** no arranque e **base completa até o fim de 2026**; plataforma multi-provedor (**OpenAI, Anthropic, Google, AWS**) com **-65% no custo de GenAI**. A imprensa financeira leu como a arma do Itaú na **guerra da principalidade**. (TI Inside · Tecnoblog · Seu Dinheiro, 27/07)

O QUE EU DIRIA NUM BOARD

Quando a conversa vira a tela inicial, o custo por interação vira o novo cost-to-income da interface — e o Itaú mostrou que ele é gerenciável com roteamento multi-provedor; quem depende de um único fornecedor de LLM não tem essa alavanca. Segundo: cada resposta sobre crédito ou investimento é potencialmente recomendação regulada — a trilha de auditoria da conversa vale mais que a UX. É o comportamento de líder do playbook NTT DATA (52,5% dos líderes "movem rápido", pág. 4) em produção. A pergunta para os demais bancos não é "se" respondem — é com que plataforma, e a que custo por conversa.

PRA USAR AMANHÃ

One-pager "custo por conversa": a arquitetura que o Itaú construiu internamente (roteamento multi-modelo + observabilidade de custo) é o que o Veltrix entrega como produto para quem não tem anos de engenharia para construí-la. O ia.i é o case de validação.

SEÇÃO 02

Governança & Risco

Stone lança a Vela: plataforma interna de IA para matar o Shadow AI

Captado fora das newsletters globais (21/07, inédito nas eds. anteriores): a **Stone** lançou a **Vela**, plataforma corporativa de IA integrada ao ecossistema Karavela, com **governança e auditoria centralizadas** — resposta explícita ao avanço do **Shadow AI** (ferramentas de IA não sancionadas usadas por funcionários). (TI Inside, 21/07)

O QUE EU DIRIA NUM BOARD

*Shadow AI é o Shadow IT com dado de cliente saindo pela porta de um prompt. A resposta certa não é bloquear — é oferecer um canal governado **mais conveniente** que o ChatGPT pessoal, senão o funcionário volta pro pessoal. O que quase ninguém instrumenta é o passo seguinte: observabilidade de custo e trilha por uso — sem isso o canal governado vira caixa-preta cara.*

PRA USAR AMANHÃ

Diagnóstico de Shadow AI em 3 perguntas: quantas ferramentas de IA seus funcionários usam? Quantas a TI sanciona? Qual dado de cliente já passou pelas outras? Abre a conversa Veltrix (canal governado com FinOps) + Cohort (trilha).

SEÇÃO 03

Soberania

CONTEXTO GLOBAL INCONTORNÁVEL

Kimi K3 libera os pesos: fronteira self-hosted vira opção real — e o banimento, letra morta

Follow-up da ed. Nº 36: em 27/07 a Moonshot AI **liberou os pesos** do Kimi K3 — **maior open-weight da história: 2,8 tri de parâmetros** (MoE, **104 bi ativos/token**), contexto de **1 mi de tokens**, multimodal, licença **MIT modificada** (uso comercial ok), desempenho próximo da fronteira sendo **2-3x mais barato de rodar**. E a carta pró-open-weights de **Nvidia e Microsoft saltou de 25 para 50 signatárias em um dia** (OpenAI e Google dentro; Amazon e Anthropic fora). (Tom's Hardware · Interconnects, 27/07 · Forbes, 25/07)

O QUE EU DIRIA NUM BOARD

*O argumento "só a nuvem americana tem modelo de fronteira" morreu esta semana. Para um banco com exigência de residência de dados, agora existe fronteira **dentro da jurisdição** — e 62,5% dos líderes já tratam soberania como preocupação de board (NTT DATA, Banking AI Leaders' Playbook 2026, pág. 5). O contraponto que eu mesmo levantaria: pesos abertos de origem chinesa trocam risco de jurisdição por risco de cadeia de suprimentos de modelo (model supply chain) — due diligence de proveniência vira item de compliance, não de engenharia.*

PRA USAR AMANHÃ

Matriz "onde roda cada carga": fronteira em nuvem (dado não sensível) × open-weight na jurisdição (dado regulado). Roteamento por jurisdição e sensibilidade é tese central do Veltrix.

SEÇÃO 04

Agentes & Força de Trabalho

CONTEXTO

OpenAI: 43,5% do uso ocupacional do ChatGPT já cruza a fronteira da profissão

Estudo **Work at the Frontier** (27/07), com **+800 mil mensagens** de usuários nos EUA: **16,8%** das mensagens de trabalho e **43,5%** das ocupacionais tratam de tarefas de **outra profissão**. O estudo não mede corte de vagas — documenta a **dissolução das fronteiras entre funções**. (OpenAI · Axios, 27/07)

Atendimento (CX) 77




Design 75



RH 69



Jurídico 56



Marketing 53



Engenharia 28



O QUE EU DIRIA NUM BOARD

Organograma por função foi desenhado para um mundo em que a tarefa definia o cargo — a IA está quebrando esse vínculo. Num banco: o redesenho de squads vai capturar mais valor que a próxima licença de copiloto; e a governança de acesso precisa migrar de "cargo" para "tarefa" — o analista de marketing que faz análise jurídica com IA opera fora do seu mandato de acesso a dados, e ninguém está olhando.

PRA USAR AMANHÃ

Mapear no cliente as 3 funções com maior uso "de fora" (CX, design, RH) e perguntar quem governa o acesso a dado sensível quando a tarefa cruza a fronteira — mandato por tarefa é o desenho do Cohort.

SEÇÃO 05

Regulatório Brasil

+ PRIMEIRA MÃO · BR

Open Finance leva saldo e limite ao Pix por Aproximação — o trilho do agentic commerce sendo pavimentado

No fim de julho, o Open Finance passou a permitir **compartilhamento de saldo e limite** ao conectar a conta no **Pix por Aproximação** (carteiras digitais) e em transferências automáticas — o usuário vê o saldo antes de transacionar. Contexto: **+100 mi de usuários ativos** e projeção de **R\$ 42 bi** de receita até o fim do ano (PwC). (Open Finance Brasil / AR News, jul/26 · TrendsCE, 08/07)

O QUE EU DIRIA NUM BOARD

Parece feature pequena, mas é infraestrutura: saldo + limite via API no momento do pagamento é exatamente o insumo que um agente de compras precisa para decidir e o que o motor de autorização precisa para aprovar. O regulador brasileiro está — sem anunciar — pavimentando o trilho do agentic commerce sobre Pix + Open Finance. Quem desenhar o ponto de autorização de agente sobre esse trilho primeiro define o padrão (eds. Nº 36-37).

APRENDIZADO DO DIA

"Roteamento de modelos" (model routing) — como o -65% do Itaú acontece

Em vez de mandar toda requisição para o modelo mais caro, uma camada intermediária **classifica a tarefa e roteia para o modelo mais barato que resolve** (aberto ou fechado, de qualquer provedor), com fallback para modelos maiores quando a confiança cai. O mesmo mecanismo que corta custo permite rotear por **jurisdição e sensibilidade do dado** — FinOps e soberania são a mesma decisão de arquitetura, tomada no mesmo ponto do stack.

SEÇÃO 06

No Radar — sinais & tendências

- **Drex: consórcios entregam relatórios de 13 casos de uso** — os 16 consórcios do piloto entregaram os relatórios; 1ª entrega confirmada para o 2º semestre/2026 em versão restrita, foco em conciliação de garantias de crédito, sem DLT nesta fase (Exame). A rota "menos blockchain, mais caso de uso" se confirma.
- **BB formaliza o NiCE Copilot no atendimento** — Copilot na interface CXone para gerentes e assistentes, com A5 Solutions (Decision Report, 24/07). Follow-up da ed. Nº 36: o agent estate do BB segue crescendo na camada de atendimento.
- **Nvidia lança iniciativa de AI safety (27/07)** — citando incidentes cibernéticos ligados a modelos não controlados. O mesmo ator que lidera a carta pró-open-weights agora vende a camada de segurança para eles: safety de open-weight vira mercado, não só política (GuruFocus).

Urgente · Atenção · Oportunidade/futuro

One Banking AI

Curadoria: Team Sector Banking

Fontes do dia: TI Inside · Tecnoblog · Seu Dinheiro (Itaú ia.i) · TI Inside (Stone Vela) · Tom's Hardware · Interconnects (Kimi K3) · Forbes (carta open-weights) · GuruFocus (Nvidia safety) · OpenAI/Axios (Work at the Frontier) · Open Finance Brasil · Exame (Drex) · Decision Report (BB) · AINews (swyx) · The Neuron · NTT DATA (Banking AI Leaders' Playbook 2026, págs. 4-5) · Síntese própria, nunca tradução integral.