

One Banking AI

IA no setor financeiro · governança · soberania · economia de IA

TERÇA-FEIRA · 11 AGO 2026 EDIÇÃO Nº 49

COMO LER ESTE BRIEFING

⚠ **Impacto direto no negócio** = movimento de cliente/concorrente/regulador que afeta a operação agora. **✦ Primeira mão** = item captado direto na fonte BR, fora das newsletters globais. Internacional entra como contexto, não como manchete.

Uso interno e confidencial — cruza com o estudo Where To Play Banking · One Banking (MTP 27-29).

TERMÔMETRO DO DIA

45%

peso de talento no Evident AI Index (base do Goldman)
▲ Seu Dinheiro

33

incidentes de segurança no SFN em 5 meses (25 de fraude)
● BC via Finsiders

US\$ 30 bi

volume anualizado de stablecoin comprado com a BVNK
✦ American Banker

< 20 GB

Muse Glimmer (30B) quantizado para rodar local
✦ CNBC

◀ A LEITURA DE HOJE

⚠ Impacto direto no negócio

✦ Primeira mão

Goldman Sachs: Nubank e Itaú disparam na corrida da IA — e o gap "pode virar irreversível"

O relatório, baseado no **Evident AI Index**, ranqueia **Nubank à frente de Itaú, Bradesco e Banco do Brasil** na maturidade de IA da América Latina, recomenda compra das ações dos dois líderes e aponta **talento como fator determinante — 45% do peso do índice**. A distância para o resto "tende a ficar mais difícil de encurtar daqui para frente" (Seu Dinheiro · BPMoney, ago/2026).

O QUE EU DIRIA NUM BOARD

Em sete dias, Moody's e Goldman declararam a mesma tese com insumos diferentes — dado transacional (Moody's) vs talento (Goldman). Os dois estão certos, e é isso que assusta: a vantagem é um **flywheel composto** (dado alimenta modelo, modelo atrai talento, talento acelera produto) — e flywheel não se compra pronto. Para o pelotão do meio, a janela de alcançar organicamente está fechando: as opções honestas viram parceria, aquisição de capability ou nicho com dado proprietário próprio. A nota EY Wave 3 da biblioteca já alertava: a estratégia custom in-house dos líderes tem como custo o **dreno de talento** — o insumo que vale 45% do jogo. Quem não paga esse dreno não deveria fingir a estratégia dos líderes.

Pergunta para qualquer banco fora do top 2: "sua estratégia de IA pressupõe talento que você comprovadamente atrai e retém — ou é a estratégia do Itaú com o orçamento de outro?"

Governança & Risco

⚠ Impacto direto no negócio

✚ Primeira mão

BC eleva IA a risco cibernético sistêmico — antes de qualquer ataque consumado

Na ata do Comef, o Banco Central afirmou que os modelos atuais **já têm capacidade de explorar vulnerabilidades tecnológicas do SFN**, embora não haja evidência de ataque integralmente conduzido por IA. Contexto: **33 incidentes de segurança em 5 meses de 2026, 25 ligados a fraude**, e 12 ataques a instituições ligadas ao Pix em quatro meses (*Finsiders · Let's Money*).

O QUE EU DIRIA NUM BOARD

*O regulador nomeou IA como vetor **sistêmico** — não "risco emergente". Defesa deixa de ser projeto do CISO e vira item de estabilidade cobrado em supervisão. E o espelho incomoda: o agente que corta custo no seu backoffice é a mesma tecnologia que o BC teme do lado do ataque. Quem tem inventário e mandato dos próprios agentes — escopo, limite, trilha (o desenho do Cohort) — responde à supervisão em dias; quem não tem, descobre o parque agêntico junto com o supervisor.*

PRA USAR AMANHÃ

Pergunta ao CISO do cliente: "qual o playbook para ataque automatizado e simultâneo a múltiplas instituições — e em quanto tempo você inventaria todos os agentes em produção?"

IA em Serviços Financeiros

Contexto internacional

Mastercard fecha a compra da BVNK: o trilha do agentic commerce está sendo comprado, não construído

Concluída em 03/08 por **US\$ 1,8 bi**, a aquisição faz da Mastercard a primeira bandeira dona de infraestrutura de liquidação em stablecoin: **US\$ 30 bi de volume anualizado, 25+ licenças em 130 mercados** e acesso direto ao SEPA instantâneo. A BVNK já integrava o Agent Pay for Machines (pagamentos autônomos entre agentes) e o consórcio **Open USD, de 140+ empresas** — incluindo Visa, Stripe e BlackRock (*American Banker · Mastercard · via Kriaris*).

O QUE EU DIRIA NUM BOARD

A camada de pagamento agente-a-agente (agent-to-agent payments) está sendo consolidada por M&A antes de existir demanda de massa — a bandeira comprou a posição de pedágio de um fluxo que ainda não aconteceu. Para o Brasil, a pergunta

não é stablecoin, é **quem processa quando o agente do cliente pagar**: Cielo, Getnet, Stone e Mercado Pago têm talvez 18 meses para decidir se serão trilho agent-ready ou ponto de captura legado. A Wake/Getnet (ed. 46) ganha outra urgência lida junto com isto.

Soberania

Meta abre os pesos do Muse Glimmer: a opção de soberania on-prem ficou mais barata

Modelo denso de **30 bilhões de parâmetros**, multimodal, treinado em **100+ idiomas**, com pesos abertos e comprimido por quantização para **menos de 20 GB** — roda em GPU de consumo (24–32 GB). Zuckerberg: "em vez de centralizar a superinteligência, devemos distribuí-la". O Spark 1.2, de fronteira, terá pesos abertos "em breve" (CNBC · TechCrunch · AINews, 10-11/08).

O QUE EU DIRIA NUM BOARD

*Soberania de dados sempre teve um preço — e ele caiu. Um modelo competente rodando inteiro dentro do perímetro muda o cálculo de residência de dados: a inferência sensível pode nunca sair de casa, sem API externa, sem transferência internacional para a LGPD discutir. A arquitetura defensável vira **roteamento por sensibilidade**: crítico no modelo local, genérico na fronteira via API — o roteamento por jurisdição que o Veltrix implementa. Contraponto real: 30B aberto não substitui fronteira em raciocínio complexo; quem vender "soberania total" com modelo local troca risco regulatório por risco de qualidade.*

PRA USAR AMANHÃ

One-pager "matriz de roteamento": 3 faixas de sensibilidade × onde a inferência roda (local aberto / nuvem soberana / API de fronteira) × custo por 1k tokens de cada faixa.

Agentes & Força de Trabalho

↗ Primeira mão

BB corta câmbio de 40 para 4 minutos com agente autônomo — e o dado honesto é a acurácia de 75%

Agente sobre Microsoft Foundry analisa documentos e monta o dossiê de câmbio de grandes empresas; funcionários revisam. Tempo médio caiu **90% (de ~40 para ~4 minutos)**, com **acurácia atual de 75%** — e o ganho virou produto: o BB estendeu em uma hora a janela de pedidos, até as 17h (Mobile Time, 15/07 · TI Inside, 27/07 — caso de julho fora das edições anteriores, registrado pelo padrão).

O QUE EU DIRIA NUM BOARD

*O case mais honesto de agente em produção no banking BR — porque publica o número imperfeito. 75% de acurácia com revisão humana obrigatória é **mandato de agente bem desenhado**: autonomia na preparação, humano na decisão, e o prêmio não é demissão — é **janela de negócio** (uma hora a mais de captação). É o*

template de promoção a produção que o Cohort formaliza. A pergunta que falta: custo de inferência por dossiê — sem ele, os 90% de tempo são metade da conta.

PRA USAR AMANHÃ

Benchmark de conversa: "qual processo seu tem 40 minutos de preparação humana e tolera revisão de saída? Esse é o primeiro agente — não o chatbot."

Economia de IA & FinOps

OpenAI recalibra: alvo de compute de US\$ 600 bi e receita projetada de US\$ 280 bi até 2030

Com mega-rodada a caminho, relatos de imprensa indicam alvo de compute moderado para **US\$ 600 bi** e projeção de **US\$ 280 bi de receita até 2030**; em paralelo, a Bloomberg reporta dificuldade de consenso entre os sócios do Stargate (US\$ 500 bi / 10 GW, ~US\$ 400 bi anunciados) (*Finviz/relatos · TechCrunch*).

O QUE EU DIRIA NUM BOARD

*Quando o fornecedor-âncora planeja gastar em compute o dobro do que projeta faturar na década, o delta aparece no preço do token ou na diluição de alguém — e o comprador corporativo não controla qual. A resposta racional não é prever, é **não depender**: multi-modelo com custo por transação medido (o terreno do Veltrix) e cláusula de portabilidade em qualquer contrato enterprise de IA.*

No Radar

- **Muse Spark 1.2 com pesos abertos "em breve"** — se confirmado, primeiro modelo de fronteira aberto do ciclo; muda de novo o preço da soberania (*ANI, 11/08*).
- **"Agentic Wars" e resultados Visa vs Mastercard** na análise de Kriaris: pagamento agêntico virou tema de earnings call de bandeira (*Kriaris, 10/08*).
- **XP entra na adquirência em agosto**: cartão e maquininha para PMEs, em teste com seis parceiros (*Startups.com.br*).
- **PL 2338**: projeto do governo, articulado com o relator, entra no texto na Câmara — acompanhar o SIA e o papel da ANPD (*Convergência Digital*).
- **Febraban vs adquirentes**: denúncia ao BC contra Mercado Pago, PagBank, PicPay e Stone por suspeita de fraude em cartões (*Finsiders*).

APRENDIZADO DO DIA

Quantização (quantization)

Reduzir a precisão numérica dos pesos de um modelo (ex.: de 16 para 4 bits por parâmetro), cortando drasticamente memória e custo de inferência com perda marginal de qualidade. É o que faz 30 bilhões de parâmetros caberem em menos de 20 GB e rodarem numa GPU de consumo — a tecnologia silenciosa por trás de duas teses desta

edição: soberania on-prem barata e deflação do custo por token. Quando disserem "modelo local não é viável", a pergunta certa é: *"quantizado a quanto?"*

Fontes do dia: Seu Dinheiro · BPMoney · Finsiders Brasil · Let's Money · Mobile Time · TI Inside · American Banker · Mastercard newsroom · CNBC · TechCrunch · AINews/Latent Space · ANI · Startups.com.br · Convergência Digital · Finviz · newsletter Panos Kriaris · The Neuron

ONE BANKING AI · EDIÇÃO Nº 49 · CURADORIA: TEAM SECTOR BANKING