

One Banking AI

IA no setor financeiro · governança · soberania · economia de IA

QUINTA-FEIRA · 13 AGO 2026 EDIÇÃO Nº 51

COMO LER ESTE BRIEFING

⚠ **Impacto direto no negócio** = movimento de cliente/concorrente/regulador que afeta a operação agora. ➡ **Primeira mão** = item captado direto na fonte BR, fora das newsletters globais. Internacional entra como contexto, não como manchete — salvo marco global incontornável, caso de hoje.

Uso interno e confidencial — cruza com o estudo Where To Play Banking · One Banking (MTP 27-29).

TERMÔMETRO DO DIA

**US\$
0,84**custo médio por
tarefa agêntica do
Grok 4.6

♦ Artificial Analysis

8,3xtokens/usuário nas
frontier firms vs
empresa típica (era
2,6x)

♦ OpenAI

1 GWmeta da coalizão
europeia de compute
da Mistral até 2030

♦ Mistral

4 diaspara um framework
multiagente comprometer
órgãos de governo

♦ Dream Security

⚡ A LEITURA DE HOJE

⚠ **Impacto direto no negócio**

A guerra de preços chegou aos agentes: Grok 4.6 entrega fronteira a metade do custo — e muda a métrica que importa

A SpaceXAI lançou o Grok 4.6 (12/08) mirando **agentes de longa duração (long-running agents)**, código e pesquisa: nota **61 na Artificial Analysis** (empatado com o GPT-5.6 Sol), preço de **US\$ 2/US\$ 6 por milhão de tokens** — cerca de metade dos rivais — e **US\$ 0,84 por tarefa concluída**. No benchmark agêntico AA-Briefcase: ~53 turnos e 0,5 bi de tokens vs ~103 turnos e 2,0 bi do Opus 5 Max. Grok 4.7 prometido em 3–4 semanas. Dia raro sem manchete nova dos bancões BR — silêncio pré-Febraban Tech.

O QUE EU DIRIA NUM BOARD

A unidade de custo da IA trocou de nome: não é mais preço por token, é **custo por tarefa concluída (cost per completed task)** — modelo "barato" que gasta o dobro de turnos sai mais caro. Para banco: (1) contrato precificado por token sem telemetria de turnos e retries é instrumento cego; (2) com fornecedores trocando de posição de preço a cada 4 semanas, ficar preso a um provedor é passivo financeiro — o Itaú entendeu e construiu a lara (ed. Nº 50). É o argumento central do Veltrix: medir custo por tarefa e re-rotear por preço/qualidade virou hedge, não

otimização. Contraponto: benchmark é fotografia — quem re-arquiteta a cada release perde mais em engenharia do que ganha em token.

Pra usar amanhã: "quanto custou a última tarefa concluída pelo seu agente — e você saberia se esse número dobrasse?"

Fonte: x.ai (12/08) · Artificial Analysis · VentureBeat · via The Neuron e AINews (13/08)

GRÁFICO DO DIA — O CUSTO ESCONDIDO DOS TURNOS

Mesma tarefa (benchmark AA-Briefcase), consumo diferente — turnos médios até concluir:

Grok 4.6 ~53 turnos
Opus 5 Max ~103 turnos

Tokens de entrada consumidos na mesma bateria:

Grok 4.6 0,5 bi
Opus 5 Max 2,0 bi

O preço por token é metade da história — a outra metade é quantos tokens o modelo precisa para terminar o serviço. Fonte: Artificial Analysis

ECONOMIA DE IA & FINOPS

OpenAI: frontier firms já queimam 8,3x mais tokens por usuário — intensidade de uso virou indicador de maturidade

Relatório da OpenAI sobre uso corporativo (12/08): as empresas de fronteira geram **8,3x mais tokens de saída por usuário ativo** que a empresa típica — há um ano a razão era **2,6x**. A distância mais que triplicou em doze meses.

O QUE EU DIRIA NUM BOARD

Lido com o Goldman/Evident (eds. 48–49), fecha o quadro: o gap de maturidade aparece primeiro **na conta de consumo**, não no resultado. Token por usuário é o proxy mais honesto de adoção real — ninguém queima inferência por vaidade em escala. Se a fatura de IA não cresce, o problema raramente é disciplina: é que ninguém usa. O KPI certo é o par **consumo por usuário × custo por tarefa** — um mede adoção, o outro eficiência; qualquer um sozinho engana.

Pra usar amanhã: medir o "índice 8,3x" da operação — tokens/usuário ativo vs o benchmark da OpenAI.

Fonte: OpenAI (12/08) · via The Neuron

GOVERNANÇA & RISCO

Framework multiagente compromete órgãos de governo na Ásia em 4 dias — ataque autônomo deixou de ser tese

A Dream Security detalhou (12/08) um sistema multiagente que **mapeou e comprometeu entidades governamentais asiáticas em quatro dias**, de forma autônoma: agentes dividiram reconhecimento, exploração e persistência entre si, sem operador humano no loop tático.

O QUE EU DIRIA NUM BOARD

Terceiro incidente agêntico em três semanas neste briefing (eds. 48–50) — e o primeiro contra Estado. A assimetria virou: o atacante opera força de trabalho de agentes; a defesa da maioria dos bancos opera tickets. (1) O SOC precisa assumir **velocidade de máquina** no adversário — 4 dias é o novo baseline, não o teto; (2) a resposta simétrica é governar os próprios agentes com mandato, escopo e trilha (o desenho do Cohort) — a primeira pergunta do regulador pós-incidente será "que agentes rodavam e com que permissões?". Sem inventário de agentes, não há resposta.

Pra usar amanhã: "se um agente nosso for comprometido hoje, em quanto tempo saberíamos — e temos a lista do que ele pode fazer?"

Fonte: Dream Security (12/08) · via The Neuron

SOBERANIA

Mistral lança inferência regional e coalizão europeia de compute de até 1 GW — a soberania ganhou um cardápio comercial

Anúncio triplo (12/08): **inferência regional** (dado processado na jurisdição escolhida), hospedagem de modelos abertos de terceiros e **coalizão europeia de compute mirando até 1 GW até 2030**.

O QUE EU DIRIA NUM BOARD

A soberania de IA está virando **SKU** — residência de dados compra-se como região de nuvem. A pergunta incômoda para o BR: a Europa monta 1 GW soberano com fornecedor regional âncora; o Brasil discute o PL 2338 sem equivalente industrial. Para um banco, o caminho pragmático é arquitetural: **roteamento por jurisdição** — decidir, por chamada, o que sai do país e o que fica (a camada que o Veltrix implementa). Lido com o Muse Glimmer aberto (ed. 49): on-prem + trilha regional formam, pela primeira vez, um portfólio completo de soberania com preço de mercado.

Pra usar amanhã: mapa de uma página: quantas chamadas de IA saem do Brasil hoje, para qual jurisdição, e o custo de repatriá-las.

Fonte: Mistral (12/08) · via The Neuron

AGENTES & FORÇA DE TRABALHO

Agentes gerenciados (managed agents): a infraestrutura de agente vira serviço — com governança embutida por padrão

A Emerging AI (12/08) destrincha a categoria aberta pelos Claude Managed Agents: em vez de montar sandbox, checkpoint, credenciais, permissões e rastreamento (tracing) por conta própria, o fornecedor entrega o **harness gerenciado** — agentes de nuvem que rodam por horas, retomam trabalho, controlam custo e coordenam entre si.

O QUE EU DIRIA NUM BOARD

O build vs buy de agentes desceu um andar: não se discute só o modelo, mas quem opera a **infraestrutura de execução**. Permissões escopadas, sandbox e trilha vêm **por padrão** — o argumento "governança atrasa o time" perdeu o lastro; virou feature de fábrica. O risco simétrico: terceirizar o harness concentra no fornecedor o registro do que seus agentes fizeram — para banco, a trilha de

auditoria precisa ser **do banco**, exportável e independente do provedor (a fronteira que o Cohort defende manter em casa).

Pra usar amanhã: cláusula para o próximo contrato de plataforma de agentes: portabilidade integral da trilha de auditoria e dos logs de permissão.

Fonte: Emerging AI (12/08) · Anthropic · InfoWorld

NO RADAR

- **Febraban Tech 2026 (24–26/08, Anhembi):** 11 dias; "Agentes Inteligentes, liderança humana" — a semana quieta nos bancões sugere anúncios guardados para o palco (Diário do Comércio)
- **Serasa Experian abre o Impulsiona Startups:** R\$ 800 mil para acelerar oito negócios; inscrições até 30/08 [+ Primeira mão](#) (Finsiders)
- **Lovable capta US\$ 400 mi a US\$ 13,3 bi** — dobrou de valuation desde dezembro; vibe coding virou categoria de capital (WSJ, 12/08)
- **Cognition negocia rodada a US\$ 40 bi** após US\$ 1 bi de receita anualizada — agentes de código em velocidade de escape (TechCrunch, 12/08)
- **Amazon/Twitch treina IA com conteúdo de streamers por padrão** (opt-out) — precedente de consentimento que a ANPD vai olhar de perto (TechCrunch, 12/08)

APRENDIZADO DO DIA — CUSTO POR TAREFA CONCLUÍDA (COST PER COMPLETED TASK)

Métrica que substitui o preço por token na avaliação de modelos para agentes: soma tudo o que a tarefa consumiu — turnos, tokens, retries — até a conclusão. Dois modelos com o mesmo preço de tabela podem diferir 4x no custo real, porque um resolve em 50 turnos o que o outro faz em 100. É o número que a Artificial Analysis passou a publicar (US\$ 0,84/tarefa no Grok 4.6) e o que deveria constar em qualquer contrato de IA. Quando alguém comparar modelos só por US\$/milhão de tokens, traduza: "estamos comparando o preço do litro sem saber o consumo do carro".

Fontes do dia: x.ai · Artificial Analysis · VentureBeat · The Neuron · AINews/Latent Space · OpenAI · Dream Security · Mistral · Emerging AI · Anthropic · InfoWorld · TechCrunch · WSJ · Finsiders · Diário do Comércio

ONE BANKING AI · EDIÇÃO Nº 51 · CURADORIA: TEAM SECTOR BANKING