

One Banking AI

IA no setor financeiro · governança · soberania · economia de IA

20 DE AGOSTO DE 2026 · QUINTA-FEIRA EDIÇÃO Nº 58

COMO LER ESTE BRIEFING

⚠ **Impacto direto no negócio** = movimento de cliente, concorrente ou regulador que afeta a operação agora. ✦ **Primeira mão** = item captado direto na fonte BR, fora das newsletters globais. Conteúdo internacional entra como contexto e comparação, não como manchete. *Uso interno e confidencial* — cruza com o estudo Where To Play Banking · One Banking (MTP 27-29).

TERMÔMETRO DO DIA

R\$ 50,4 bi

orçamento tecnológico dos bancos BR em 2026
· +8% vs. 2025, +58% em 5 anos

▲ Febraban/Deloitte, jun/2026

US\$ 7 bi+

pago pela camada de roteamento (Stripe/OpenRouter) · 5,4x a avaliação de maio/2026

● fechado em 19/08

**0,45 x
1,84**

custo médio por tarefa, em US\$, com e sem roteamento de modelo

◆ Latent Space, 18/08

4 dias

para o Febraban Tech · 7 CEOs no painel de abertura, 24/08 às 10h20

◆ contagem regressiva

◀ A LEITURA DE HOJE

⚠ IMPACTO DIRETO NO NEGÓCIO

Na segunda-feira, sete CEOs de bancos brasileiros sobem ao mesmo palco para falar de agentes. Na noite de ontem, uma empresa de pagamentos comprou por US\$ 7 bilhões a camada que decide qual modelo atende cada chamada de agente. Essa camada não aparece em nenhuma linha dos R\$ 50,4 bilhões que o setor vai gastar em 2026.

Os fatos, na ordem. Segunda, **24/08 às 10h20**, o Febraban Tech abre com Maluhy Filho (Itaú), Tarciana Medeiros (BB), Noronha (Bradesco), Livia Chanes (Nubank), Finkelsztain (Santander), Carlos Vieira (Caixa) e Sallouti (BTG) no painel "Agentes Inteligentes, Liderança Humana". A Pesquisa Febraban/Deloitte, feita com **25 bancos** (≈85% dos ativos) e 53 executivos, projeta **R\$ 50,4 bi** de investimento em 2026 — **+8%** sobre 2025, **+58%** em cinco anos, com GenAI e cloud prioritários para **84%**. E o fato de ontem: a **Stripe fechou a compra da OpenRouter por mais de US\$ 7 bi** — **5,4x** a avaliação de US\$ 1,3 bi de maio, três meses antes —, levando **400+ modelos** de **80+**

provedores atrás de um endpoint. Do outro lado do mercado, a Glean opera a **US\$ 0,45/tarefa** contra **US\$ 1,84** — 4x — e credita a diferença a harness e roteamento.

O QUE EU DIRIA NUM BOARD

Pare no detalhe que quase ninguém comentou — **quem comprou o roteador foi uma empresa de pagamentos**. A Stripe não comprou um modelo, nem GPU, nem dataset. Comprou o **switch**. E empresa de pagamento compra switch porque entende, melhor que ninguém, que quem fica no meio do fluxo captura margem, vê o volume e escreve a regra — a mesma lógica que fez o adquirente valer o que vale no cartão. Traduzindo para a nossa casa: **a decisão de roteamento de modelo é, ao mesmo tempo, decisão de custo unitário, de latência e de jurisdição** — e hoje, na maioria dos bancos brasileiros, ela é tomada por um desenvolvedor dentro de um arquivo de configuração, sem passar por nenhum comitê. Os R\$ 50,4 bi são um número de **entrada**, como o índice Evident de ontem era um placar de entrada. Ninguém publica R\$/tarefa — mas agora existe preço de mercado para a competência de reduzir esse número: US\$ 7 bilhões, 5,4x em três meses.

Contraponto sério, e com bons defensores: roteamento agressivo troca custo por qualidade e por complexidade operacional — mais modelos significa mais superfícies de avaliação, mais variabilidade e um pesadelo de reprodutibilidade quando o regulador pedir para explicar uma decisão de crédito de seis meses atrás; e o número da Glean é autorrelato de fornecedor sobre concorrente. Aceito os dois pontos inteiros — trato o 4x como ordem de grandeza, não como fato contábil. Mas eles não derrubam a tese, deslocam a exigência: se roteamento aumenta variabilidade, então **roteamento sem registro é que é inaceitável**, e a resposta não é rotear menos, é **registrar tudo**.

Minha posição: todo banco que colocar agente em produção precisa de uma **política de roteamento escrita e versionada**, com três colunas — classe de tarefa, modelo permitido, jurisdição de processamento — e um log por chamada que responda, meses depois, qual modelo atendeu, quanto custou e sob que lei o dado foi processado. Quem não tiver isso vai descobrir o custo da IA pelo extrato, e a jurisdição pelo ofício.

PRA USAR AMANHÃ

Antes de segunda, peça uma coisa só ao time de plataforma: **a lista de modelos que sua operação chamou nos últimos 30 dias, com volume, custo e região de processamento**. Se não existir ou levar mais de um dia para sair, você não tem arquitetura de IA — tem um conjunto de integrações. É esse inventário que o **Veltrix** entrega por construção, e é sobre ele que o **Cohort** escreve o mandato: qual agente chama qual modelo, com que teto e sob que trilha.

SEÇÃO 01

IA em Serviços Financeiros

Cluster liderado por bancos e fintechs brasileiros.

Custo médio por tarefa — com e sem roteamento de modelo

em US\$ por tarefa · autorrelato de fornecedor, tratar como ordem de grandeza · fonte: Latent Space, 18/08/2026

Glean (harness + roteamento) **US\$ 0,45**

Claude Code (sem roteamento) **US\$ 1,84**

A diferença de **4x** não vem de preço de token — vem de **montar o contexto antes de escolher o modelo**. A conta de IA da maioria dos bancos não é problema de tarifa, é problema de contexto mal montado.

PRINCIPAL

△ IMPACTO DIRETO NO NEGÓCIO

✦ PRIMEIRA MÃO

Febraban Tech 2026: sete CEOs, um palco e o tema que virou pauta de conselho

A 36ª edição acontece de **24 a 26/08** no Distrito Anhembi, com **42 mil m²** (+71% de área sobre 2025) e dez auditórios. Tema: "**Agentes Inteligentes, Liderança Humana**". A abertura, em **24/08 das 10h20 às 11h30**, reúne os presidentes de **Itaú, Banco do Brasil, Bradesco, Nubank, Santander Brasil, Caixa e BTG Pactual**. [Febraban](#) · [Cryptoid](#)

O QUE EU DIRIA NUM BOARD

Quando sete concorrentes diretos aceitam sentar no mesmo palco para falar do mesmo assunto, o assunto deixou de ser diferencial e virou **infraestrutura setorial** — como foi o Pix, como foi o Open Finance. Consequência prática: a partir de agora, "estamos investindo em agentes" não distingue ninguém no seu conselho. O que distingue é a segunda camada da resposta — **com que mandato, a que custo por tarefa e com qual trilha de auditoria**. Contraponto: painel de CEO é vitrine institucional, não estratégia. Verdade — mas vitrine cria compromisso público, e em fevereiro alguém cobra o que foi dito em agosto.

PRA USAR AMANHÃ

Leve três perguntas ao evento e não saia sem resposta: (1) o agente tem teto de gasto por execução? (2) quem aprova a promoção de piloto para produção? (3) qual dado sai da jurisdição brasileira e sob que base legal?

COMÉRCIO AGÊNTICO

✦ PRIMEIRA MÃO

Getnet projeta US\$ 17,5 trilhões em comércio agêntico; Cielo põe agente de pagamento com Google Cloud

A **Getnet** (Santander) detalhou estratégia de **comércio agêntico (agentic commerce)** — agentes que iniciam, gerenciam e executam compras —, projetando que até **30% do valor transacionado no e-commerce global** seja influenciado por agentes até **2030**, cerca de **US\$ 17,5 trilhões**. A **Cielo** apresentou no Fórum E-Commerce Brasil plataforma de pagamento com agentes construída com o **Google Cloud**: busca, escolha e finalização dentro da conversa, com cartão salvo ou QR Code do Pix. [IT Forum](#) · [Exame](#)

O QUE EU DIRIA NUM BOARD

Os dois maiores adquirentes do país estão construindo a mesma coisa — **um trilho para o agente pagar** — e isso reabre em silêncio a questão mais espinhosa do meio de pagamento: **quem é o portador quando o pagador é um software?** Consentimento, autenticação e responsabilidade por transação não autorizada foram desenhados supondo um humano na ponta. A única defesa jurídica real é a **prova do mandato**: o que o cliente autorizou, com que limite, por quanto tempo, e o registro de que o agente ficou dentro disso. Sobre o número: **US\$ 17,5 tri é projeção de fornecedor para 2030** — direção, não base de business case. Contraponto: exigir arquitetura de mandato antes de haver volume atrasa o produto. Concorro com o risco — mas quem lança sem mandato registrado paga fraude em dinheiro e reputação em audiência pública.

PRA USAR AMANHÃ

Pegue o desenho de comércio agêntico que estiver na sua mesa e responda em uma frase: **onde está guardado o mandato do agente e o que exatamente ele autoriza?** Se for "está no prompt", é o gap que o **Cohort** fecha.

COOPERATIVISMO

✦ PRIMEIRA MÃO

Sicoob lança "Sebah", agente de IA para operações de TI

O **Sicoob** anunciou o **Sebah**, agente de IA para apoiar a área de **Operações de TI** em automação de processos, análise de dados e geração de informação para decisão.

[ClicSoledade](#)

O QUE EU DIRIA NUM BOARD

Registro porque contraria a narrativa de que agente em banco é assunto de bancão. O **cooperativismo de crédito** está colocando agente em produção — e começando pelo lugar certo: **TI interna**, onde o erro é caro mas contido, não no cliente final. É o caminho que eu recomendaria a qualquer instituição de porte médio. Ressalva: agente com acesso a operações de TI tem privilégio alto por definição — comprometimento ali não vira reclamação de cliente, vira incidente sistêmico.

SEÇÃO 02

Economia de IA & FinOps

O custo unitário de rodar IA — o número que ninguém publica.

PRINCIPAL

⚠ IMPACTO DIRETO NO NEGÓCIO

Stripe compra a OpenRouter: roteamento de modelo virou infraestrutura de pagamento

A **Stripe** fechou a aquisição da **OpenRouter** por **mais de US\$ 7 bilhões** (NYT: US\$ 7,5 bi; Axios: acima de US\$ 8 bi) — **5,4x** a avaliação de **US\$ 1,3 bi** da Série B de **maio/2026**, três meses antes. A OpenRouter agrega **400+ modelos** de **80+ provedores** num endpoint único, roteando cada requisição por complexidade, preço, velocidade e confiabilidade.

[Stripe](#) · [CNBC 19/08](#) · [SiliconANGLE](#)

O QUE EU DIRIA NUM BOARD

5,4x em três meses não é preço de tecnologia, é preço de posição. A Stripe não comprou modelo, GPU nem dataset — comprou o **switch**. E empresa de pagamento compra switch porque entende, melhor que ninguém, que quem fica no meio do fluxo captura margem, vê o volume e escreve a regra. Para uma instituição brasileira o alerta é específico: se a camada de roteamento consolida em poucos players estrangeiros, **a decisão de onde seu dado é processado vira parâmetro de um produto de terceiro**. Contraponto: comprar roteamento pronto é mais barato e rápido que construir, e ninguém deveria querer um roteador de 400 modelos como diferencial. Concordo — a questão não é build vs. buy, é **quem escreve a política**. Compre o trilho; a política de jurisdição e o log têm que ser seus.

PRA USAR AMANHÃ

Inclua cláusula de **residência de processamento por classe de dado** na próxima renovação de contrato de fornecedor de IA. Não "cumpra a LGPD" — a região física e o direito de auditar.

FINOPS

Glean: US\$ 0,45 por tarefa contra US\$ 1,84 — e a corrida por peso aberto (open-weights)

Segundo o cofundador **Tony Gentilcore**, a Glean é "4x mais custo-efetiva" que o Claude Code — **US\$ 0,45/tarefa** contra **US\$ 1,84** —, atribuído a harness e roteamento. O CEO **Arvind Jain** diz que modelos de fronteira custam "**o dobro ou o quádruplo** por token" das gerações anteriores e que empresas gastam "**10 a 20 vezes mais por usuário**" que no ano passado. O modelo **Waldo** reduz **latência em 50%** e **tokens em 25%** montando o contexto antes de acionar o modelo caro. Sobre peso aberto: "**ninguém mais aceita depender de um ou dois provedores**". [Latent Space, 18/08/2026](#)

O QUE EU DIRIA NUM BOARD

O achado técnico que importa não é o preço — é a **ordem das operações**. A Glean monta o contexto *antes* de escolher o modelo, e por isso um modelo barato com contexto certo bate um modelo de fronteira com contexto irrelevante. Isso inverte o instinto padrão de arquitetura em banco, que é "na dúvida, chama o maior". **A conta de IA da sua instituição provavelmente não é problema de preço de token — é problema de contexto mal montado**. Contraponto: 4x é número de fornecedor sobre concorrente, sem árbitro, em carga de trabalho escolhida por ele. Aceito integralmente — por isso a recomendação não é adotar Glean, é **medir a sua**. E levaria a última frase ao comitê: se ninguém mais aceita depender de um ou dois provedores, **multi-provedor deixou de ser tese e virou requisito de continuidade** — e requisito de continuidade tem dono, prazo e teste.

PRA USAR AMANHÃ

Rode a mesma tarefa três vezes — fronteira, intermediário e aberto — com o contexto que você já monta hoje, e registre custo, latência e taxa de acerto. É o experimento de uma tarde que dá a base do seu próprio R\$/tarefa.

SEÇÃO 03

Governança & Risco

PRINCIPAL

⚠️ IMPACTO DIRETO NO NEGÓCIO

O Banco Central vai operar o modelo: score de risco de fraude do Pix com IA e ML

O BC desenvolve um **score de risco de fraude centralizado**, com **IA e aprendizado de máquina (machine learning)**, alimentado por **SPI** e **DICT**, para entrega **em tempo real** aos participantes do Pix — prioridade da agenda evolutiva do **biênio 2026-2027**, segundo **Renato Gomes**, diretor de Organização do Sistema Financeiro e de Resolução: "a decisão de autorizar ou rejeitar uma transação depende de cada participante". No mesmo arcabouço: **Res. BCB 501** (rejeição compulsória com fundada suspeita), **522** (define "risco de fraude" e "risco de golpe") e **524** (participante direto do SPI deve detectar, em tempo real e por padrão comportamental, movimentação atípica **na própria Conta PI**). [Finsiders](#) · [Radar Regulatório](#)

O QUE EU DIRIA NUM BOARD

O item mais subestimado da semana. **O regulador brasileiro está deixando de ser normatizador de modelo para virar operador de modelo.** Um score público, centralizado e em tempo real sobre SPI e DICT muda a natureza do jogo antifraude: o diferencial migra do *score* para **o que você faz com ele**. Duas consequências. Primeira: "a decisão depende de cada participante" é garantia de autonomia e transferência de responsabilidade — quando o BC sinalizar risco alto e você aprovar, a pergunta no sancionador será por que você aprovou. Segunda: a **Res. 524** inverte a perspectiva histórica, que era exógena (olhar o cliente), e obriga a olhar **para dentro** — isso é, na prática, obrigação regulatória de modelo próprio de anomalia sobre a sua operação. Contraponto legítimo: score centralizado cria **monocultura de risco** — o fraudador só precisa aprender a enganar **um** modelo, e o erro do BC vira erro de todos, simultaneamente. Risco real, que eu levaria ao comitê. A resposta não é recusar o sinal: **é nunca deixá-lo ser o único**, mantendo modelo próprio como camada independente e medindo divergência.

PRA USAR AMANHÃ

Monte hoje a régua de convivência: tabela de quatro células (BC alto/você baixo; BC baixo/você alto; ambos altos; ambos baixos), e para cada uma **quem decide e o que fica registrado**. Se não existir quando o score entrar no ar, ela será escrita no meio de um incidente.

SEÇÃO 04

Soberania da Informação

400 modelos, 80 provedores, um endpoint — e nenhuma pergunta sobre jurisdição

A consolidação da camada de roteamento (Stripe/OpenRouter) e a adoção acelerada de **peso aberto (open-weights)** relatada pela Glean produzem o mesmo efeito por caminhos opostos: **a escolha do modelo deixa de ser explícita**. No primeiro caso é delegada a um intermediário; no segundo, pulverizada entre provedores de inferência. Em ambos, quem chama a API deixa de saber, por padrão, onde o dado foi processado.

O QUE EU DIRIA NUM BOARD

A tese que ficou mais fácil de sustentar esta semana: **roteamento é decisão de jurisdição disfarçada de decisão de engenharia**. Um roteador que escolhe "o melhor modelo por preço, velocidade e confiabilidade" escolhe, junto e sem dizer, o país onde o dado do seu cliente é processado e a lei que se aplica. Ou seja: a conformidade com a **LGPD** pode estar sendo definida por um parâmetro de otimização de custo. A defesa não é proibir roteamento — é **tornar a jurisdição critério de primeira classe do roteador**, no mesmo nível de preço e latência. Contraponto: pinar jurisdição encarece e reduz disponibilidade, e a maioria do dado que trafega num agente interno não é pessoal sensível. Correto — por isso a resposta é **classificação, não proibição**: dado público roteia livre, dado pessoal roteia em jurisdição declarada, dado sensível não sai. Três regras, não um comitê.

PRA USAR AMANHÃ

Escreva a matriz de três linhas — classe de dado × jurisdição permitida × modelos elegíveis — e transforme em **configuração**, não em política de PDF. É o que o **Veltrix** implementa como roteamento por jurisdição e sensibilidade.

SEÇÃO 05

Regulatório Brasil

MARCO LEGAL

PL 2338 segue parado na Câmara enquanto o setor acelera

O **PL 2338/2023** foi aprovado no **Senado em 10/12/2024** e remetido à **Câmara em março/2025**. A Comissão Especial (presidência de **Luísa Canziani**, relatoria de **Aguinaldo Ribeiro**) fez **doze audiências públicas** em 2025; a votação foi **adiada para 2026** por falta de consenso. O texto segue o modelo do **EU AI Act** — classificação por risco, direitos de transparência/explicação/contestação, criação do **SIA** e sanções de até **R\$ 50 milhões** por infração. [Senado](#) · [Câmara](#)

O QUE EU DIRIA NUM BOARD

O descompasso é o ponto. O setor vai aplicar **R\$ 50,4 bi** em 2026 com agentes em produção, e a lei que vai classificar esses sistemas por risco ainda não foi votada. Quem esperar o texto para começar a governar vai ter que **retroagir governança sobre sistemas já em produção** — a forma mais cara que existe de fazer isso. E note: o vácuo não é vácuo. O **Bacen** já está regulando IA no financeiro por outra via, a das resoluções de fraude e de qualidade de dados. **A regulação de IA no setor financeiro**

brasileiro está chegando pelo regulador setorial, não pelo marco legal.

Contraponto: legislar rápido sobre tecnologia em movimento produz lei obsoleta, e o adiamento pode ser prudência. Justo — mas prudência do legislador não é desculpa para imprudência do administrador.

PRA USAR AMANHÃ

Mapeie seus sistemas de IA contra a classificação de risco do PL 2338 **agora**, com o texto do Senado. Se um cair em "alto risco" — crédito e biometria caem —, esse é o seu backlog de conformidade dos próximos doze meses.

SEÇÃO 06

No Radar

Sinais a monitorar nos próximos dias.

Segunda, 24/08, 10h20

Abertura do Febraban Tech com sete CEOs. O que vou procurar no discurso: alguém cita **custo por tarefa** ou só **volume de casos**?

Resolução Conjunta nº 18

Política de qualidade de dados obrigatória até o **fim de 2026**; o prazo virou o maior risco. Governança de dado é pré-requisito de governança de IA, nessa ordem.

MED 2.0

Nova versão do mecanismo de devolução do Pix, com rastreamento **além da primeira camada**. Muda a economia da fraude: hoje o golpista se protege pulverizando.

Consolidação do roteamento

Depois da Stripe, observar quem compra o quê. Se um adquirente ou bandeira comprar roteamento, "switch de token" deixa de ser analogia.

APRENDIZADO DO DIA · ROTEAMENTO DE MODELO (MODEL ROUTING)

O que é: a camada que decide, a cada requisição, qual modelo vai atender — por complexidade da tarefa, preço, latência e confiabilidade. Em vez de o código apontar para um modelo fixo, aponta para o roteador.

Por que importa pra quem decide: a mesma tarefa pode custar 4x mais ou 4x menos dependendo dessa decisão, tomada milhões de vezes por mês sem passar por alçada. Três coisas viajam juntas e quase nunca são discutidas juntas: **custo unitário**, **qualidade** e **jurisdição de processamento**.

A pergunta de board: "quem, na nossa casa, escreveu a regra de roteamento — e onde ela está registrada?" Se a resposta for um nome de pessoa e um arquivo de configuração, você tem risco operacional com aparência de detalhe técnico.

- Febraban — Presidentes dos maiores bancos debatem o impacto dos agentes inteligentes
- Febraban / Deloitte — Pesquisa Febraban de Tecnologia Bancária 2026 (34ª ed., vol. 1)
- Stripe Newsroom — Stripe agrees to acquire OpenRouter
- CNBC, 19/08/2026 — Stripe to buy OpenRouter as fintech expands deeper into AI
- SiliconANGLE, 19/08/2026 — Stripe buys AI model router OpenRouter in reported \$7.5B deal
- Latent Space, 18/08/2026 — Frontier Model Cost and Open-Weights Popularity is Driving Demand for Model Routing
- Finsiders — BC planeja usar IA em novo 'score' de risco de fraudes com Pix
- Finsiders — A regulação do Pix na corrida antifraude (Res. BCB 501, 522, 524)
- IT Forum — Getnet detalha estratégia para comércio agêntico
- Exame — Como funcionará o novo agente de IA da Cielo
- ClicSoledade — Sicoob lança "Sebah", agente de IA para operações de TI
- Senado — PL 2338/2023
- Finsiders — Resolução Conjunta nº 18: prazo vira o maior risco da qualidade de dados
- Cryptoid — Febraban Tech 2026 começa em 24 de agosto em novo local

Curadoria: Team Sector Banking

One Banking AI · Edição Nº 58 · 20 de agosto de 2026 · quinta-feira

Uso interno e confidencial. Síntese editorial, nunca tradução integral. Cruza com o estudo Where To Play Banking · One Banking (MTP 27-29).
